UTS

PEMBELAJARAN MESIN



NAMA : Said Aqiel Syafaraz

NIM : 202431100

KELAS : H

DOSEN : Rizqia Cahyaningtyas, ST., M.Kom

NO.PC :

ASISTEN : 1. Muhammad Ichwan Fauzi

2. Benedict Samuel Ardy

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

BAB I PENDAHULUAN **3**
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 4
BAB II LANDASAN TEORI **5**
2.1 Pembelajaran Mesin dan Supervised Learning 5
2.2 Diabetes dan Pemanfaatan Pembelajaran Mesin pada Data Klinis 5
2.3 Exploratory Data Analysis dan Preprocessing 5
2.4 Algoritma Decision Tree 6
2.5 Algoritma Regresi Linear 7
2.6 Metrik Evaluasi dan Ketidakseimbangan Kelas 7
2.7 Ringkasan Penelitian Terdahulu 8
BAB III HASIL **10**
3.1 Gambaran Dataset 10
3.2 Langkah 1: Import Library dan Konfigurasi 10
3.3 Langkah 2: Memuat Dataset 11
3.4 Langkah 3: Memahami Dataset (Data Understanding) 11
3.5 Langkah 4: EDA: Kualitas Data (Missing Value, Duplikat, Kategori) 12
3.6 Langkah 5: EDA: Distribusi Variabel Target 12
3.7 Langkah 6: EDA: Distribusi Fitur Numerik dan Deteksi Outlier 13
3.8 Langkah 7: EDA: Hubungan Fitur dengan Target 13
3.9 Langkah 8: EDA: Matriks Korelasi 14
3.10 Langkah 9: Preprocessing: Pembersihan dan Encoding 14
3.11 Langkah 10: Pembagian Data Latih dan Data Uji 15
3.12 Langkah 11: Standardisasi Fitur untuk Regresi Linear 15
3.13 Langkah 12: Decision Tree: Model Dasar 16
3.14 Langkah 13: Decision Tree: Tuning Hyperparameter dengan GridSearchCV 16
3.15 Langkah 14: Decision Tree: Evaluasi Lengkap 17
3.16 Langkah 15: Decision Tree: Visualisasi Pohon dan Feature Importance 17
3.17 Langkah 16: Regresi Linear: Pelatihan Model 18
3.18 Langkah 17: Regresi Linear: Evaluasi 18
3.19 Langkah 18: Perbandingan Decision Tree dan Regresi Linear 19
3.20 Langkah 19: Uji Prediksi pada Contoh Pasien Baru 19
3.21 Langkah 20: Ringkasan Hasil Otomatis 20
3.22 Rekapitulasi dan Analisis Hasil 20
BAB IV PENUTUP **23**
DAFTAR PUSTAKA **24**

BAB I
PENDAHULUAN

1.1 Rumusan Masalah

Diabetes melitus merupakan penyakit kronis yang mengganggu proses pengolahan glukosa di dalam tubuh sehingga kadar gula darah menjadi tidak terkendali (Shaukat dkk., 2023). Deteksi yang terlambat meningkatkan risiko komplikasi, sehingga dibutuhkan pendekatan berbasis data yang mampu membantu proses penapisan pasien. Pada UTS Pembelajaran Mesin ini digunakan dataset 02_diabetes.csv yang memuat 100.000 catatan pasien dengan delapan atribut klinis dan demografis serta satu atribut target biner (diabetes), dan dikerjakan dengan algoritma Decision Tree dan Regresi Linear menggunakan bahasa pemrograman Python. Berdasarkan hal tersebut, rumusan masalah pada praktikum ini adalah sebagai berikut.

1. Bagaimana karakteristik dan kualitas dataset diabetes berdasarkan hasil Exploratory Data Analysis (EDA), meliputi distribusi data, nilai hilang, data duplikat, outlier, dan korelasi antarvariabel?
2. Bagaimana tahapan preprocessing yang diperlukan agar dataset dapat dilatih menggunakan algoritma Decision Tree dan Regresi Linear?
3. Bagaimana kinerja algoritma Decision Tree dalam memprediksi diabetes, dan fitur apa yang paling berpengaruh terhadap hasil prediksi?
4. Bagaimana kinerja algoritma Regresi Linear pada target biner dan bagaimana perbandingannya dengan Decision Tree berdasarkan akurasi serta metrik evaluasi lainnya?

1.2 Tujuan Masalah

Tujuan yang ingin dicapai dari praktikum UTS ini adalah sebagai berikut.

1. Memahami struktur dan kualitas dataset diabetes melalui proses EDA yang meliputi statistik deskriptif, visualisasi distribusi, deteksi data duplikat dan outlier, serta analisis korelasi.
2. Menerapkan tahapan preprocessing berupa penghapusan data duplikat, penanganan kategori yang jarang muncul, encoding variabel kategorikal, pembagian data latih dan uji, serta standardisasi fitur.
3. Melatih, menyetel (hyperparameter tuning), dan mengevaluasi model Decision Tree serta Regresi Linear menggunakan Python di Google Colab.
4. Memperoleh nilai akurasi dan metrik evaluasi lain (presisi, recall, F1-score, dan ROC-AUC) dari kedua model, kemudian membandingkan dan menganalisis hasilnya berdasarkan teori dan jurnal pendukung.

1.3 Manfaat Masalah

Manfaat yang diperoleh dari praktikum UTS ini adalah sebagai berikut.

1. Manfaat teoretis: memperdalam pemahaman mengenai alur kerja pembelajaran mesin terawasi (supervised learning) secara utuh, mulai dari pemahaman data, preprocessing, pelatihan model, hingga evaluasi, serta memahami perbedaan karakter algoritma berbasis pohon dan algoritma linear.
2. Manfaat praktis: menghasilkan model prediksi awal risiko diabetes yang dapat dijadikan gambaran bagaimana data klinis sederhana seperti HbA1c, kadar glukosa darah, usia, dan indeks massa tubuh dimanfaatkan untuk mendukung penapisan pasien.
3. Manfaat bagi mahasiswa: melatih kemampuan menulis kode Python yang terdokumentasi, menafsirkan keluaran model, serta menyusun laporan ilmiah yang didukung oleh jurnal terbaru.

BAB II
LANDASAN TEORI

2.1 Pembelajaran Mesin dan Supervised Learning

Pembelajaran mesin (machine learning) adalah cabang kecerdasan buatan yang memungkinkan komputer mempelajari pola dari data tanpa diprogram secara eksplisit untuk setiap aturan. Pada pembelajaran terawasi (supervised learning), model dilatih menggunakan data berlabel, yaitu pasangan fitur masukan dan target keluaran, sehingga model dapat memprediksi target untuk data baru yang belum pernah dilihat. Apabila target berupa kategori, masalah tersebut disebut klasifikasi; apabila target berupa nilai kontinu, masalah tersebut disebut regresi. Pada dataset yang digunakan dalam praktikum ini, target diabetes bernilai 0 (tidak diabetes) atau 1 (diabetes), sehingga secara alami merupakan masalah klasifikasi biner. Meskipun demikian, penugasan UTS mewajibkan penggunaan Regresi Linear, sehingga keluaran kontinu dari regresi dikonversi menjadi kelas melalui sebuah ambang batas (threshold) agar dapat dibandingkan secara adil dengan Decision Tree.

2.2 Diabetes dan Pemanfaatan Pembelajaran Mesin pada Data Klinis

Diabetes mengganggu mekanisme tubuh dalam mengolah glukosa, yang merupakan sumber energi utama bagi sel (Shaukat dkk., 2023). Data klinis seperti kadar glukosa darah, tekanan darah, dan indeks massa tubuh (BMI) dapat dianalisis oleh algoritma pembelajaran mesin untuk menemukan pola yang berkaitan dengan penyakit ini sehingga dapat membantu dokter dalam menganalisis kondisi pasien (Sen Kaya dkk., 2023). Berbagai penelitian terbaru menunjukkan bahwa algoritma seperti Decision Tree, Logistic Regression, Random Forest, KNN, dan SVM telah banyak diterapkan pada data diabetes, baik pada dataset publik seperti PIMA maupun pada data pasien rumah sakit (Nguyen dkk., 2023; Shaukat dkk., 2023). Hal ini menunjukkan bahwa pendekatan berbasis data relevan untuk dijadikan studi kasus pada praktikum ini.

Dataset yang digunakan memuat variabel demografis (gender dan age), riwayat penyakit (hypertension dan heart_disease), riwayat merokok (smoking_history), serta indikator klinis berupa bmi, HbA1c_level, dan blood_glucose_level. HbA1c mencerminkan rata-rata kadar gula darah dalam beberapa bulan terakhir, sedangkan blood_glucose_level merupakan kadar glukosa darah saat pengukuran. Kedua indikator ini secara klinis erat kaitannya dengan diagnosis diabetes sehingga diperkirakan menjadi fitur yang dominan dalam model.

2.3 Exploratory Data Analysis dan Preprocessing

Exploratory Data Analysis (EDA) adalah tahap awal analisis untuk memahami struktur data sebelum pemodelan, meliputi pemeriksaan tipe data, statistik deskriptif, nilai hilang (missing value), data duplikat, distribusi variabel, outlier, dan hubungan antarvariabel melalui matriks korelasi. Hasil

EDA menjadi dasar keputusan preprocessing. Pada data klinis, pemeriksaan distribusi kelas target sangat penting karena kasus positif biasanya jauh lebih sedikit daripada kasus negatif.

Preprocessing yang diterapkan pada praktikum ini mencakup empat hal. Pertama, penghapusan data duplikat agar satu catatan tidak dihitung berulang dan tidak menimbulkan kebocoran informasi antara data latih dan data uji. Kedua, penanganan kategori yang sangat jarang muncul. Ketiga, encoding variabel kategorikal karena algoritma yang digunakan hanya dapat memproses angka; variabel biner seperti gender dipetakan menjadi 0 dan 1, sedangkan variabel dengan banyak kategori seperti smoking_history diubah dengan one-hot encoding. Keempat, standardisasi fitur (z-score) agar setiap fitur berada pada skala yang sebanding, yaitu $z = (x - \mu) / \sigma$. Standardisasi diperlukan oleh model linear namun tidak diperlukan oleh Decision Tree karena pohon hanya membandingkan nilai ambang pada satu fitur dalam satu waktu. Parameter standardisasi harus dihitung hanya dari data latih untuk mencegah kebocoran data (data leakage).

Data kemudian dibagi menjadi data latih dan data uji. Data latih digunakan agar model mempelajari pola, sedangkan data uji digunakan untuk menilai kemampuan generalisasi pada data baru. Pada data yang tidak seimbang, pembagian dilakukan secara berstrata (stratified) agar proporsi kelas pada data latih dan data uji tetap sama dengan data asli.

2.4 Algoritma Decision Tree

Decision Tree adalah algoritma yang membangun model berbentuk struktur pohon. Setiap simpul internal merepresentasikan pengujian terhadap satu fitur (misalnya HbA1c $\leq$ 6,7), setiap cabang merepresentasikan hasil pengujian, dan setiap daun merepresentasikan keputusan kelas. Algoritma ini membagi data secara rekursif dengan memilih fitur dan nilai ambang yang menghasilkan simpul anak paling "murni". Kemurnian simpul diukur dengan Gini impurity atau entropi.

$$Gini(t) = 1 - \Sigma\, p_i^2 \qquad Entropi(t) = -\Sigma\, p_i \log_2 p_i$$

dengan p_i adalah proporsi kelas ke-i pada simpul t. Nilai Gini atau entropi sama dengan nol apabila seluruh data pada simpul berasal dari satu kelas. Pada kriteria entropi, pemilihan pemisahan didasarkan pada information gain, yaitu selisih entropi simpul induk dengan rata-rata tertimbang entropi simpul anak. Keunggulan Decision Tree adalah aturan keputusannya mudah ditafsirkan, mampu menangkap hubungan non-linear dan interaksi antarfitur, serta tidak peka terhadap perbedaan skala fitur. Kelemahan utamanya adalah kecenderungan overfitting, yaitu pohon tumbuh sangat dalam sehingga menghafal data latih dan kinerjanya turun pada data uji.

Untuk mengendalikan overfitting digunakan pembatasan pertumbuhan pohon (pre-pruning) melalui hyperparameter seperti max_depth (kedalaman maksimum) dan min_samples_leaf (jumlah

minimum data pada daun), yang pada praktikum ini dicari kombinasi terbaiknya menggunakan GridSearchCV dengan validasi silang 5 lipatan. Decision Tree juga menyediakan feature importance, yaitu seberapa besar kontribusi suatu fitur dalam menurunkan impurity, sehingga dapat dipakai untuk menjelaskan fitur mana yang paling menentukan prediksi. Dalam literatur diabetes terbaru, Decision Tree sering dijadikan model dasar yang dibandingkan dengan metode ensemble. Sen Kaya dkk. (2023) membandingkan Decision Tree, Bagging dengan Decision Tree, Random Forest, dan Extra Trees dan memperoleh akurasi tertinggi 99,2% dengan Extra Trees, sedangkan Cai dkk. (2024) menemukan bahwa Random Forest memiliki daya prediksi gabungan terkuat dibandingkan nomogram dan Decision Tree dalam memprediksi nefropati diabetik pada pasien diabetes tipe 2.

2.5 Algoritma Regresi Linear

Regresi Linear memodelkan hubungan antara satu variabel target kontinu dengan beberapa fitur sebagai kombinasi linear. Untuk p fitur, model dituliskan sebagai berikut.

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p$$

dengan β_0 sebagai intersep dan β_j sebagai koefisien fitur ke-j. Koefisien diestimasi dengan metode kuadrat terkecil biasa (Ordinary Least Squares) yang meminimalkan jumlah kuadrat selisih antara nilai aktual dan nilai prediksi. Apabila fitur sudah distandardisasi, besar koefisien dapat dibandingkan antarfitur sebagai gambaran kekuatan pengaruhnya, dan tanda koefisien menunjukkan arah pengaruh (positif atau negatif).

Pada target biner (0 atau 1), Regresi Linear menghasilkan nilai kontinu yang dapat ditafsirkan sebagai estimasi peluang, sehingga disebut pula model peluang linear (linear probability model). Nilai prediksi dapat berada di luar rentang 0 sampai 1 dan klasifikasi dilakukan dengan ambang batas, umumnya 0,5. Keterbatasan ini perlu diperhatikan. Cerono dan Chicco (2024) menyebutkan bahwa regresi linear klasik sering terbatas oleh hubungan non-linear, heterogenitas efek, dan dimensi data yang tinggi. Pada penelitian tersebut, yang memodelkan durasi diabetes dari rekam medis elektronik, Random Forest menjadi prediktor terbaik, sedangkan Regresi Linear memperoleh R^2 sebesar 0,14 dan 0,09 pada dua dataset, lebih baik daripada Decision Tree yang memperoleh R^2 sebesar 0,05 dan −0,21. Temuan ini menunjukkan bahwa perbandingan Decision Tree dan Regresi Linear sangat bergantung pada karakteristik data dan konfigurasi model, termasuk apakah pohon telah dikendalikan kedalamannya.

2.6 Metrik Evaluasi dan Ketidakseimbangan Kelas

Evaluasi klasifikasi berangkat dari confusion matrix yang memuat True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN). Dari matriks tersebut diturunkan metrik berikut.

$$Akurasi = (TP + TN) / (TP + TN + FP + FN) \qquad Presisi = TP / (TP + FP)$$

$$Recall = TP / (TP + FN) \qquad F1 = 2 \times Presisi \times Recall / (Presisi + Recall)$$

Akurasi menunjukkan proporsi prediksi yang benar, presisi menunjukkan seberapa tepat prediksi positif, recall (sensitivitas) menunjukkan seberapa banyak kasus positif yang berhasil ditemukan, dan F1-score adalah rata-rata harmonik presisi dan recall. ROC-AUC mengukur kemampuan model memisahkan dua kelas pada berbagai ambang batas. Pada konteks medis, recall sangat penting karena kasus diabetes yang terlewat (FN) berarti pasien tidak tertangani.

Pada Regresi Linear, kualitas prediksi kontinu diukur dengan Mean Absolute Error (MAE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE), dan koefisien determinasi R^2. Shaukat dkk. (2023) menggunakan kombinasi metrik klasifikasi (TPR, FPR, presisi, recall, F-measure, Matthews correlation coefficient, area ROC, dan area PR) serta metrik galat (MAE, RMSE, RAE, dan RRSE), sedangkan Cerono dan Chicco (2024) memakai R^2, RMSE, MAE, MSE, dan SMAPE untuk menilai model regresi.

Dataset diabetes pada praktikum ini tidak seimbang, yaitu hanya sekitar 8,5% data berlabel positif. Pada kondisi demikian akurasi dapat memberi kesan keliru karena model yang selalu menebak kelas mayoritas pun sudah memperoleh akurasi tinggi. Owusu-Adjei dkk. (2023) dalam tinjauan sistematisnya pada bidang kesehatan menegaskan bahwa penilaian dengan skor akurasi yang tidak memperhitungkan distribusi kelas dapat menimbulkan kesan keliru tentang model yang tampak berkinerja tinggi. Oleh karena itu, laporan ini tidak hanya melaporkan akurasi, tetapi juga presisi, recall, F1-score, ROC-AUC, dan confusion matrix.

2.7 Ringkasan Penelitian Terdahulu

Tabel 2.1 merangkum penelitian terbaru yang dijadikan acuan pada praktikum ini.

Tabel 2.1 Ringkasan penelitian terdahulu yang relevan

Peneliti (Tahun)	Algoritma / Data	Temuan Utama
Shaukat dkk. (2023)	Decision Tree, KNN, Random Forest, Logistic Regression, SVM pada dataset PIMA (Python dan WEKA)	Logistic Regression terbaik dengan presisi 81% (Python) dan 80,43% (WEKA).
Sen Kaya dkk. (2023)	Decision Tree, Bagging DT, Random Forest, Extra Trees pada prediksi diabetes tahap awal	Akurasi tertinggi 99,2% diperoleh Extra Trees.
Nguyen dkk. (2023)	Decision Tree, Logistic Regression, SVC, AdaBoost, Gradient Boosting, Random Forest, KNN pada data pasien DM tipe 2 di Ninh Binh, Vietnam	Membandingkan banyak algoritma untuk membantu dokter dalam deteksi dan penilaian risiko diabetes.

Peneliti (Tahun)	Algoritma / Data	Temuan Utama
Ghiasi dkk. (2024)	Decision Tree, Random Forest, XGBoost, LGBM untuk deteksi diabetes	Mengevaluasi empat algoritma berbasis pohon dan memilih yang berkinerja terbaik.
Cai dkk. (2024)	Nomogram, Decision Tree, Random Forest untuk nefropati diabetik pada DM tipe 2	Random Forest memiliki daya prediksi gabungan terkuat.
Cerono & Chicco (2024)	Regresi (Linear Regression, Decision Tree, Random Forest, XGBoost) untuk durasi diabetes	Random Forest terbaik; Linear Regression (R^2 0,14 dan 0,09) mengungguli Decision Tree (R^2 0,05 dan −0,21).
Owusu-Adjei dkk. (2023)	Tinjauan sistematis metrik evaluasi pada data kelas tidak seimbang di bidang kesehatan	Akurasi saja dapat menyesatkan; perlu metrik yang memperhitungkan distribusi kelas.

BAB III
HASIL

Praktikum dikerjakan secara individu menggunakan bahasa pemrograman Python pada Google Colab dengan pustaka pandas, NumPy, Matplotlib, Seaborn, dan scikit-learn. Setiap sel kode diberi watermark NIM berupa komentar pada baris pertama sel. Seed acak ditetapkan 42 agar hasil dapat direproduksi. Bab ini menjelaskan setiap sel kode (Langkah 1 sampai Langkah 20) beserta hasil keluarannya. Pada akhir setiap langkah disediakan kotak untuk menempelkan tangkapan layar kode dan keluarannya.

3.1 Gambaran Dataset

Dataset 02_diabetes.csv terdiri dari 100.000 baris dan 9 kolom. Deskripsi setiap kolom disajikan pada Tabel 3.1.

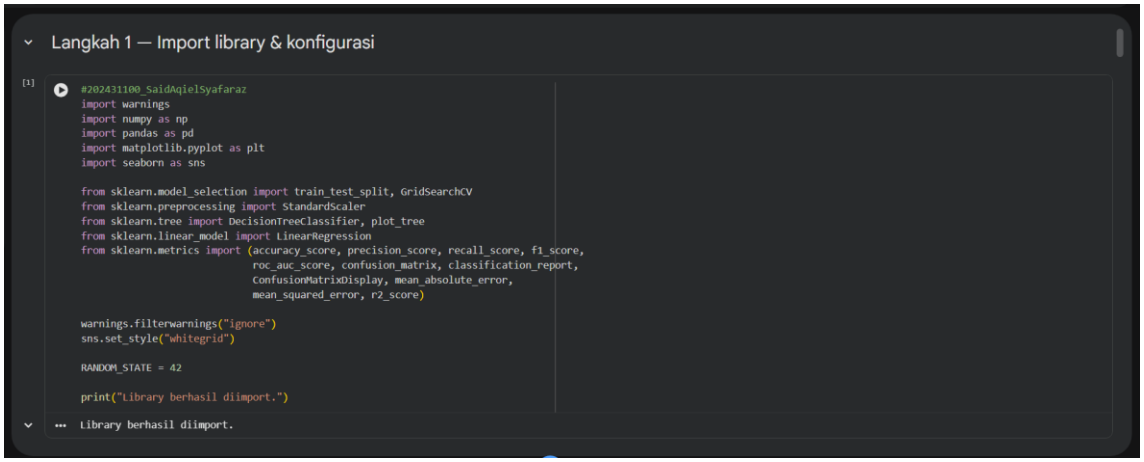
Tabel 3.1 Deskripsi variabel dataset

Kolom	Tipe	Keterangan
gender	Kategorikal	Jenis kelamin (Female, Male, Other)
age	Numerik	Usia pasien (0,08 sampai 80 tahun)
hypertension	Biner (0/1)	Riwayat hipertensi
heart_disease	Biner (0/1)	Riwayat penyakit jantung
smoking_history	Kategorikal	Riwayat merokok (No Info, never, former, current, not current, ever)
bmi	Numerik	Indeks massa tubuh (10,01 sampai 95,69)
HbA1c_level	Numerik	Kadar HbA1c (3,5 sampai 9,0)
blood_glucose_level	Numerik	Kadar glukosa darah (80 sampai 300)
diabetes	Biner (0/1) — target	0 = tidak diabetes, 1 = diabetes

3.2 Langkah 1: Import Library dan Konfigurasi

Sel pertama mengimpor pustaka yang dibutuhkan: pandas dan NumPy untuk pengolahan data, Matplotlib dan Seaborn untuk visualisasi, serta scikit-learn untuk pembagian data, standardisasi, model DecisionTreeClassifier dan LinearRegression, GridSearchCV, dan fungsi metrik evaluasi. Pada sel ini juga didefinisikan konstanta RANDOM_STATE = 42 agar hasil dapat direproduksi. Baris pertama sel berisi komentar watermark NIM.

Keluaran berupa pesan "Library berhasil diimport". Tidak ada galat, sehingga lingkungan siap digunakan.



Gambar 3.1 Tangkapan layar kode dan keluaran Langkah 1

3.3 Langkah 2: Memuat Dataset

Fungsi files.upload() menampilkan tombol unggah pada Colab sehingga file 02_diabetes.csv dapat dipilih dari komputer. File dibaca dengan pd.read_csv() ke dalam DataFrame df. Blok try-except disediakan agar kode tetap berjalan bila dijalankan di komputer lokal.

Dataset berhasil dimuat dengan ukuran (100000, 9), yaitu 100.000 baris dan 9 kolom.

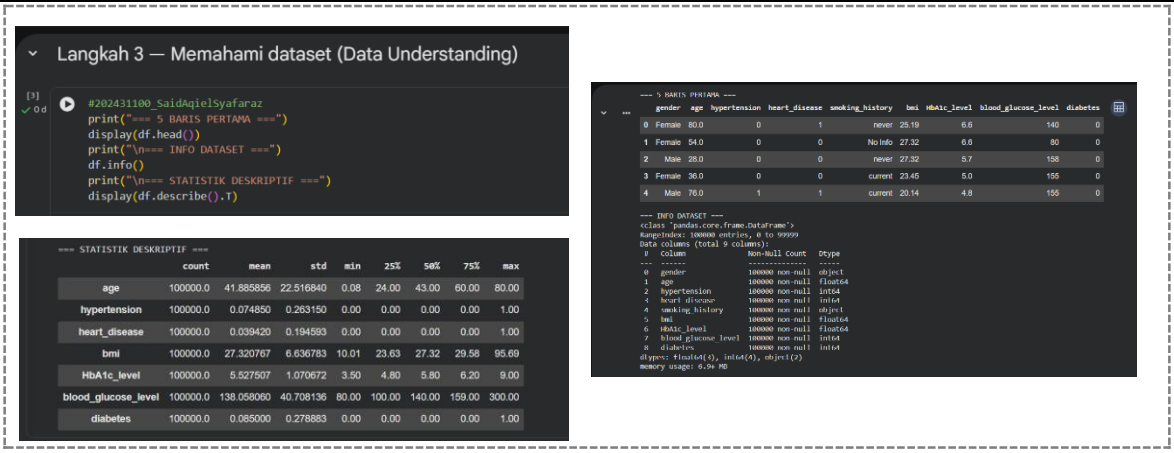


Gambar 3.2 Tangkapan layar kode dan keluaran Langkah 2

3.4 Langkah 3: Memahami Dataset (Data Understanding)

Sel ini memanggil df.head() untuk melihat lima baris pertama, df.info() untuk melihat tipe data dan jumlah nilai tidak null, serta df.describe() untuk statistik deskriptif (rata-rata, simpangan baku, minimum, kuartil, dan maksimum).

Terdapat 2 kolom kategorikal (gender dan smoking_history) dan 7 kolom numerik, dan seluruh kolom terisi penuh (100.000 non-null). Rata-rata usia 41,89 tahun, BMI 27,32, HbA1c 5,53, dan glukosa darah 138,06 mg/dL. Rata-rata kolom diabetes sebesar 0,085 menunjukkan sekitar 8,5% pasien berlabel positif.



Gambar 3.3 Tangkapan layar kode dan keluaran Langkah 3

3.5 Langkah 4: EDA: Kualitas Data (Missing Value, Duplikat, Kategori)

Kode memanggil df.isnull().sum() untuk menghitung nilai hilang per kolom, df.duplicated().sum() untuk menghitung baris yang identik, dan value_counts() untuk melihat sebaran kategori pada gender dan smoking_history.

Tidak ada nilai hilang pada seluruh kolom. Ditemukan 3.854 baris duplikat. Pada gender terdapat Female 58.552, Male 41.430, dan Other hanya 18 data. Pada smoking_history terdapat enam kategori, dengan No Info (35.816) dan never (35.095) paling banyak. Kategori Other yang sangat sedikit dan baris duplikat menjadi bahan keputusan pada tahap preprocessing.



Gambar 3.4 Tangkapan layar kode dan keluaran Langkah 4

3.6 Langkah 5: EDA: Distribusi Variabel Target

Kode menghitung jumlah dan persentase tiap kelas pada kolom diabetes, kemudian membuat diagram batang menggunakan sns.countplot() lengkap dengan label jumlah di atas batang.

Kelas 0 (tidak diabetes) berjumlah 91.500 (91,5%) dan kelas 1 (diabetes) berjumlah 8.500 (8,5%), atau rasio sekitar 10,8 : 1. Data tergolong tidak seimbang. Akibatnya, model yang selalu memprediksi "tidak diabetes" sudah akan memperoleh akurasi sekitar 91%, sehingga akurasi saja tidak cukup dan perlu dilengkapi presisi, recall, dan F1-score.



Gambar 3.5 Tangkapan layar kode dan keluaran Langkah 5

3.7 Langkah 6: EDA: Distribusi Fitur Numerik dan Deteksi Outlier

Untuk empat fitur numerik (age, bmi, HbA1c_level, blood_glucose_level), kode membuat histogram dengan kurva KDE dan boxplot dalam satu kanvas 2 × 4. Selanjutnya outlier dihitung dengan aturan IQR, yaitu data di luar rentang Q1 − 1,5 × IQR hingga Q3 + 1,5 × IQR.

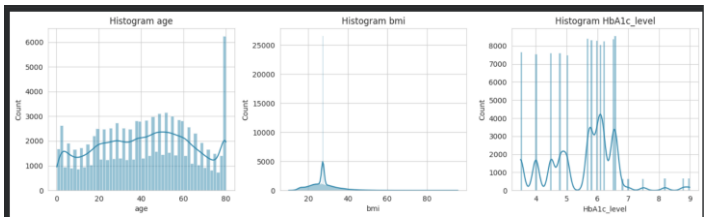
Jumlah outlier: age 0 data, bmi 7.086 data (7,09%), HbA1c_level 1.315 data (1,31%), dan blood_glucose_level 2.038 data (2,04%). Outlier tidak dihapus karena nilai tersebut masih masuk akal secara klinis (misalnya glukosa hingga 300 mg/dL) dan mewakili pasien nyata; selain itu Decision Tree tidak peka terhadap outlier. Pengaruh outlier pada Regresi Linear dicatat sebagai keterbatasan.

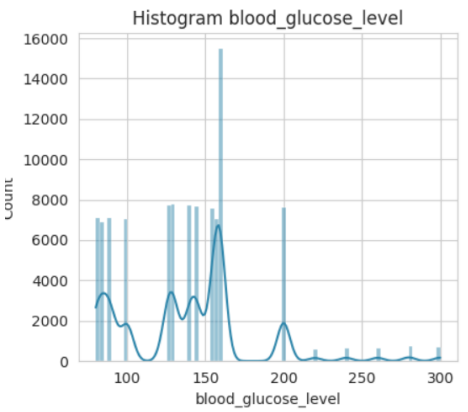
Langkah 6 — EDA: distribusi fitur numerik & deteksi outlier

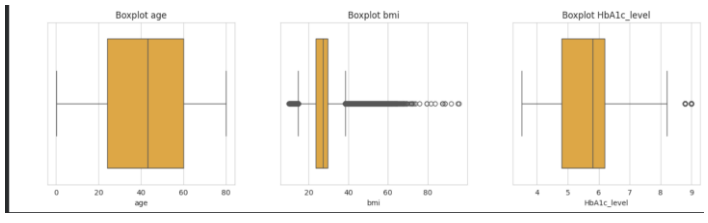
```
#202431100_SaidAqielSyafaraz
num_cols = ["age", "bmi", "HbA1c_level", "blood_glucose_level"]

fig, axes = plt.subplots(2, 4, figsize=(18, 8))
for i, col in enumerate(num_cols):
    sns.histplot(df[col], kde=True, ax=axes[0, i], color="#2E86AB")
    axes[0, i].set_title(f"Histogram {col}")
    sns.boxplot(x=df[col], ax=axes[1, i], color="#F6AE2D")
    axes[1, i].set_title(f"Boxplot {col}")
plt.tight_layout(); plt.show()

# Hitung jumlah outlier dengan aturan IQR
print("=== JUMLAH OUTLIER (aturan IQR) ===")
for col in num_cols:
    q1, q3 = df[col].quantile([0.25, 0.75])
    iqr = q3 - q1
    n_out = ((df[col] < q1 - 1.5*iqr) | (df[col] > q3 + 1.5*iqr)).sum()
    print(f"{col:22s}: {n_out} data ({n_out/len(df)*100:.2f}%)")
```









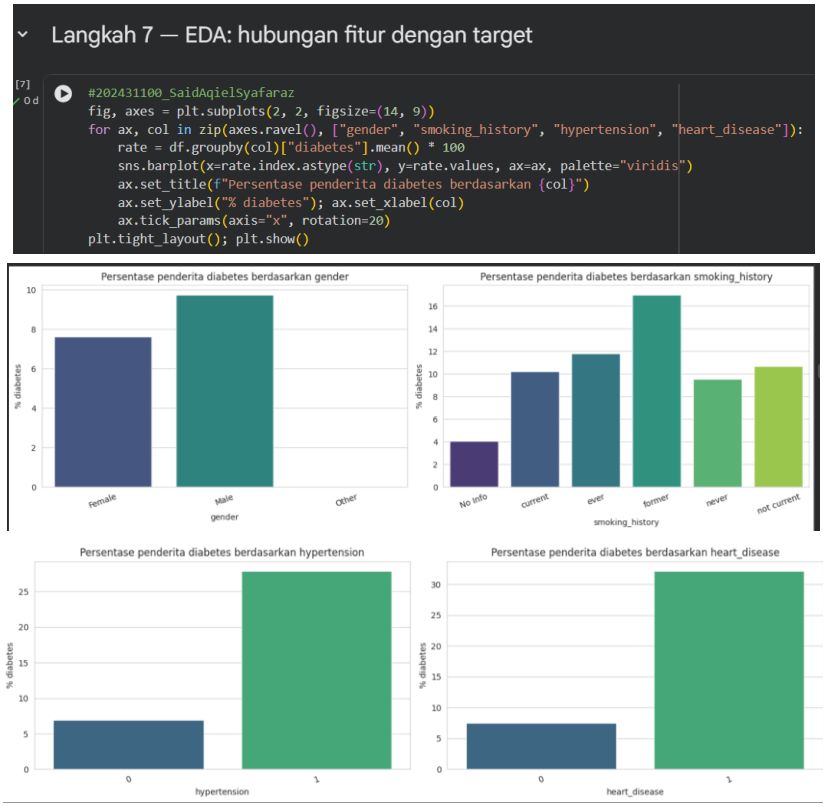

```
=== JUMLAH OUTLIER (aturan IQR) ===
age                 : 0 data (0.00%)
bmi                 : 7086 data (7.09%)
HbA1c_level         : 1315 data (1.31%)
blood_glucose_level : 2038 data (2.04%)
```

Gambar 3.6 Tangkapan layar kode dan keluaran Langkah 6

3.8 Langkah 7: EDA: Hubungan Fitur dengan Target

Kode menghitung persentase penderita diabetes pada setiap kategori gender, smoking_history, hypertension, dan heart_disease menggunakan groupby(), lalu menampilkannya dalam empat diagram batang.

Persentase diabetes pada pasien hipertensi (27,90%) jauh lebih tinggi daripada yang tidak hipertensi (6,93%). Pada pasien dengan penyakit jantung angkanya 32,14% dibandingkan 7,53%. Laki-laki (9,75%) sedikit lebih tinggi daripada perempuan (7,62%). Pada riwayat merokok, kategori former tertinggi (17,00%) dan No Info terendah (4,06%). Rata-rata pasien diabetes lebih tua (60,95 vs 40,12 tahun), memiliki BMI lebih tinggi (31,99 vs 26,89), HbA1c lebih tinggi (6,93 vs 5,40), dan glukosa lebih tinggi (194,09 vs 132,85).



Gambar 3.7 Tangkapan layar kode dan keluaran Langkah 7

3.9 Langkah 8: EDA: Matriks Korelasi

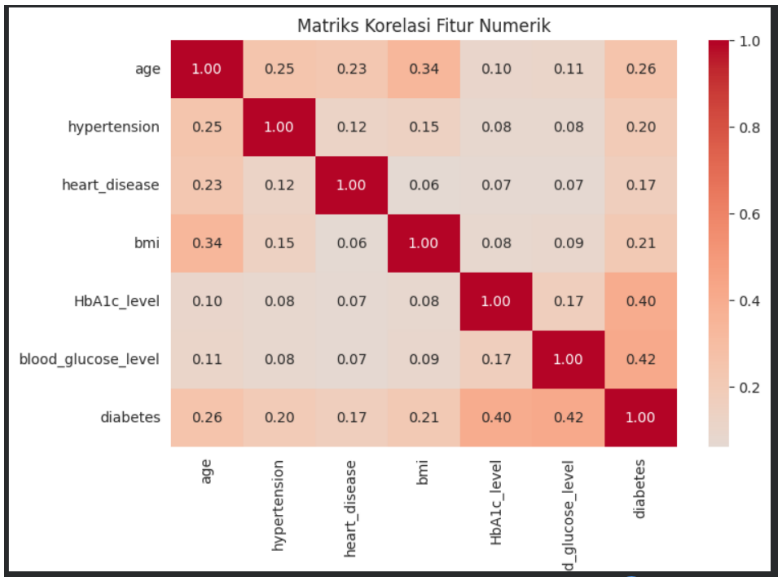
Kode menghitung korelasi Pearson antarfitur numerik dengan df.corr(), menampilkannya sebagai heatmap Seaborn, lalu mengurutkan korelasi setiap fitur terhadap target diabetes.

Korelasi terhadap target dari yang tertinggi: blood_glucose_level 0,420, HbA1c_level 0,401, age 0,258, bmi 0,214, hypertension 0,198, dan heart_disease 0,172. Seluruhnya positif, tetapi tidak ada korelasi yang sangat kuat, sehingga hubungan dengan target bersifat sedang. Glukosa darah dan HbA1c menjadi kandidat fitur paling informatif.

Langkah 8 — EDA: matriks korelasi

```
[8]
0d
#202431100_SaidAqielSyafaraz
korelasi = df.select_dtypes(include="number").corr()
fig, ax = plt.subplots(figsize=(8, 6))
sns.heatmap(korelasi, annot=True, fmt=".2f", cmap="coolwarm", center=0, ax=ax)
ax.set_title("Matriks Korelasi Fitur Numerik")
plt.tight_layout(); plt.show()

print("Korelasi fitur terhadap target 'diabetes':")
print(korelasi["diabetes"].drop("diabetes").sort_values(ascending=False).round(3))
```




```
Korelasi fitur terhadap target 'diabetes':
blood_glucose_level    0.420
HbA1c_level            0.401
age                    0.258
bmi                    0.214
hypertension           0.198
heart_disease          0.172
Name: diabetes, dtype: float64
```

Gambar 3.8 Tangkapan layar kode dan keluaran Langkah 8

3.10 Langkah 9: Preprocessing: Pembersihan dan Encoding

Kode menyalin df menjadi df_clean, kemudian (1) menghapus baris duplikat dengan drop_duplicates(), (2) membuang kategori gender Other karena hanya 18 data, (3) memetakan gender menjadi Female = 0 dan Male = 1, dan (4) melakukan one-hot encoding pada smoking_history dengan pd.get_dummies(drop_first=True) agar tidak terjadi dummy variable trap.

Sebanyak 3.854 baris duplikat dan 18 baris gender Other dihapus. Dataset bersih berukuran (96128, 13): 12 fitur ditambah 1 target, dan tidak ada nilai hilang. Kolom smoking_history berubah menjadi lima kolom biner (current, ever, former, never, not current).

Langkah 9 — Preprocessing: pembersihan & encoding

```
[9]
✓ 0d
#202431100_SaidAqielSyafaraz
df_clean = df.copy()

# 1) Hapus baris duplikat
sebelum = len(df_clean)
df_clean = df_clean.drop_duplicates()
print(f"Duplikat dihapus      : {sebelum - len(df_clean)} baris")

# 2) Hapus kategori 'Other' pada gender (hanya 18 data, terlalu sedikit)
sebelum = len(df_clean)
df_clean = df_clean[df_clean["gender"] != "Other"]
print(f"Gender 'Other' dihapus: {sebelum - len(df_clean)} baris")

# 3) Encoding gender -> biner (Female = 0, Male = 1)
df_clean["gender"] = df_clean["gender"].map({"Female": 0, "Male": 1})

# 4) One-Hot Encoding smoking_history (drop_first menghindari dummy variable trap)
df_clean = pd.get_dummies(df_clean, columns=["smoking_history"], drop_first=True, dtype=int)

df_clean = df_clean.reset_index(drop=True)
print("\nUkuran data setelah preprocessing:", df_clean.shape)
display(df_clean.head())
print("Missing value tersisa:", df_clean.isnull().sum().sum())
```

```
Duplikat dihapus      : 3854 baris
Gender 'Other' dihapus: 18 baris

Ukuran data setelah preprocessing: (96128, 13)
```

	gender	age	hypertension	heart_disease	bmi	HbA1c_level	blood_glucose_level	diabetes	smoking_history_current	smoking_history_ever	smoking_history_former	smoking_
0	0	80.0	0	1	25.19	6.6	140	0	0	0	0	
1	0	54.0	0	0	27.32	6.6	80	0	0	0	0	
2	1	28.0	0	0	27.32	5.7	158	0	0	0	0	
3	0	36.0	0	0	23.45	5.0	155	0	1	0	0	
4	1	76.0	1	1	20.14	4.8	155	0	1	0	0	

```
Missing value tersisa: 0
```

Gambar 3.9 Tangkapan layar kode dan keluaran Langkah 9

3.11 Langkah 10: Pembagian Data Latih dan Data Uji

Fitur X dipisahkan dari target y, kemudian train_test_split() membagi data dengan rasio 80 : 20, random_state = 42, dan stratify = y agar proporsi kelas terjaga.

Diperoleh 76.902 data latih dan 19.226 data uji dengan 12 fitur. Proporsi penderita diabetes sama pada kedua bagian, yaitu 8,82%, sehingga data uji merepresentasikan kondisi data asli.

Langkah 10 — Pembagian data latih & uji (80 : 20, stratified)

```
[10]
✓ 0d
#202431100_SaidAqielSyafaraz
X = df_clean.drop(columns="diabetes")
y = df_clean["diabetes"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=RANDOM_STATE, stratify=y)

print("X_train:", X_train.shape, "| X_test:", X_test.shape)
print("Proporsi diabetes pada data latih :", round(y_train.mean()*100, 2), "%")
print("Proporsi diabetes pada data uji   :", round(y_test.mean()*100, 2), "%")
```

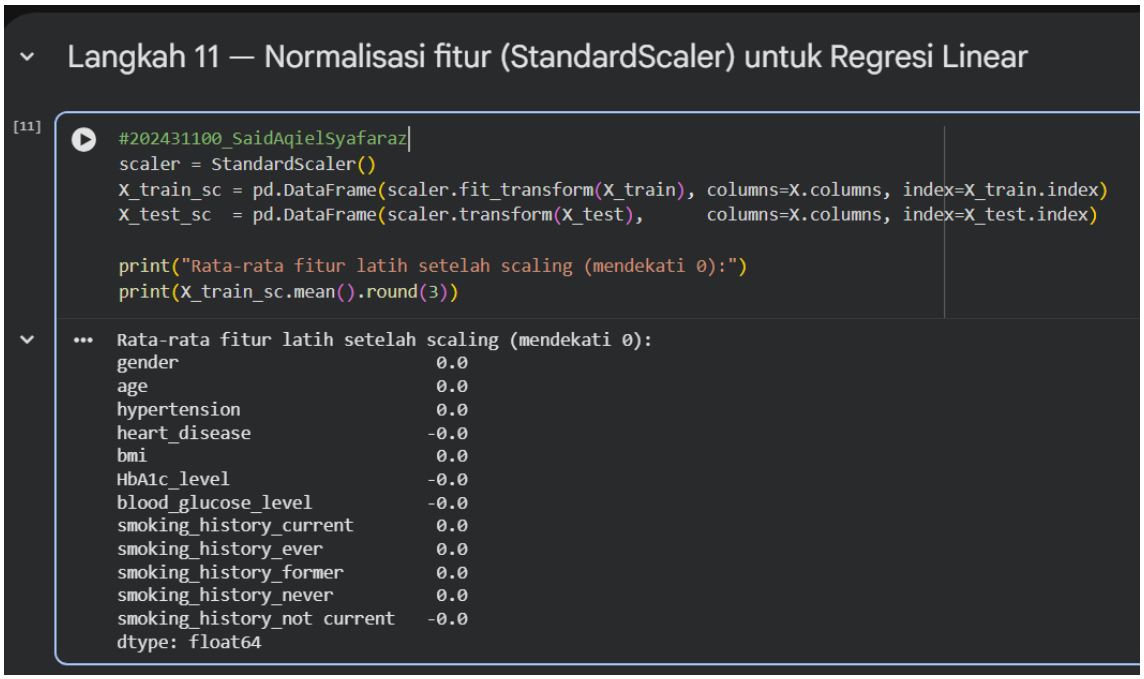
```
X_train: (76902, 12) | X_test: (19226, 12)
Proporsi diabetes pada data latih : 8.82 %
Proporsi diabetes pada data uji   : 8.82 %
```

Gambar 3.10 Tangkapan layar kode dan keluaran Langkah 10

3.12 Langkah 11: Standardisasi Fitur untuk Regresi Linear

StandardScaler di-fit hanya pada data latih (fit_transform), kemudian diterapkan pada data uji (transform) untuk mencegah kebocoran data. Hasilnya disimpan sebagai X_train_sc dan X_test_sc. Decision Tree tetap memakai data asli karena tidak peka terhadap skala.

Rata-rata seluruh fitur latih setelah standardisasi bernilai 0 (dibulatkan), yang menandakan standardisasi berhasil.

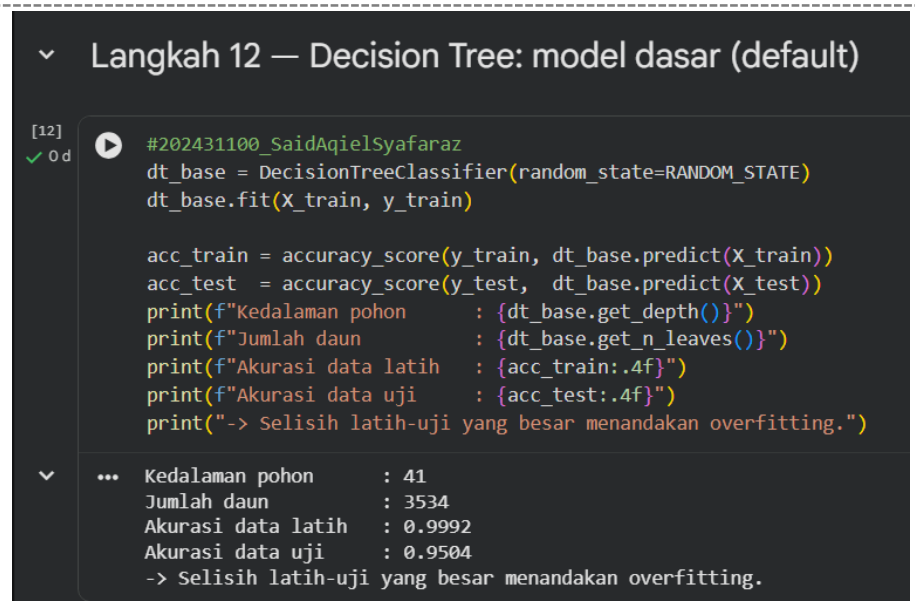


Gambar 3.11 Tangkapan layar kode dan keluaran Langkah 11

3.13 Langkah 12: Decision Tree: Model Dasar

DecisionTreeClassifier dilatih dengan parameter bawaan tanpa pembatasan kedalaman, kemudian akurasi pada data latih dan data uji dibandingkan untuk mendeteksi overfitting.

Pohon tumbuh sangat dalam dengan kedalaman 41 dan 3.534 daun. Akurasi latih 0,9992 (99,92%) sedangkan akurasi uji 0,9504 (95,04%). Selisih sekitar 4,9 poin menunjukkan overfitting karena pohon menghafal data latih.



Gambar 3.12 Tangkapan layar kode dan keluaran Langkah 12

3.14 Langkah 13: Decision Tree: Tuning Hyperparameter dengan GridSearchCV

GridSearchCV menguji kombinasi criterion (gini, entropy), max_depth (3, 4, 5, 6, 8, 10), dan min_samples_leaf (1, 10, 50) dengan validasi silang 5 lipatan serta skor F1 sebagai penentu, karena data tidak seimbang. Model terbaik disimpan sebagai dt_best.

Parameter terbaik adalah criterion = gini, max_depth = 10, dan min_samples_leaf = 50 dengan F1 rata-rata validasi silang 0,8032. Akurasi latih 0,9710 dan akurasi uji 0,9719. Selisih latih dan uji hampir nol, artinya overfitting teratasi dan akurasi uji naik dari 95,04% menjadi 97,19%.

Langkah 13 — Decision Tree: tuning hyperparameter (GridSearchCV)

[13] ✓ 27 d

```
#202431100_SaidAqielSyafaraz
param_grid = {
    "criterion": ["gini", "entropy"],
    "max_depth": [3, 4, 5, 6, 8, 10],
    "min_samples_leaf": [1, 10, 50],
}
grid = GridSearchCV(DecisionTreeClassifier(random_state=RANDOM_STATE),
                    param_grid, cv=5, scoring="f1", n_jobs=-1)
grid.fit(X_train, y_train)

dt_best = grid.best_estimator_
print("Parameter terbaik :", grid.best_params_)
print(f"F1 rata-rata CV   : {grid.best_score_:.4f}")
print(f"Akurasi data latih: {accuracy_score(y_train, dt_best.predict(X_train)):.4f}")
print(f"Akurasi data uji  : {accuracy_score(y_test,  dt_best.predict(X_test)):.4f}")
```

```
Parameter terbaik : {'criterion': 'gini', 'max_depth': 10, 'min_samples_leaf': 50}
F1 rata-rata CV   : 0.8032
Akurasi data latih: 0.9710
Akurasi data uji  : 0.9719
```

Gambar 3.13 Tangkapan layar kode dan keluaran Langkah 13

3.15 Langkah 14: Decision Tree: Evaluasi Lengkap

Model dt_best memprediksi data uji. Kode menghitung akurasi, presisi, recall, F1-score, dan ROC-AUC, mencetak classification report, serta menampilkan confusion matrix.

Akurasi 0,9719, presisi 0,9882, recall 0,6893, F1-score 0,8121, dan ROC-AUC 0,9719. Confusion matrix: TN = 17.516, FP = 14, FN = 527, dan TP = 1.169. Model sangat jarang salah menuduh pasien sehat (hanya 14 kasus), tetapi masih melewatkan 527 dari 1.696 pasien diabetes (recall 68,93%).

Langkah 14 — Decision Tree: evaluasi lengkap

```
#202431100_SaidAqielSyafaraz
y_pred_dt  = dt_best.predict(X_test)
y_prob_dt  = dt_best.predict_proba(X_test)[:, 1]

hasil_dt = {
    "Akurasi":   accuracy_score(y_test, y_pred_dt),
    "Presisi":   precision_score(y_test, y_pred_dt),
    "Recall":    recall_score(y_test, y_pred_dt),
    "F1-Score":  f1_score(y_test, y_pred_dt),
    "ROC-AUC":   roc_auc_score(y_test, y_prob_dt),
}
for k, v in hasil_dt.items():
    print(f"{k:10s}: {v:.4f}")

print("\n=== CLASSIFICATION REPORT ===")
print(classification_report(y_test, y_pred_dt, target_names=["Tidak Diabetes", "Diabetes"]))

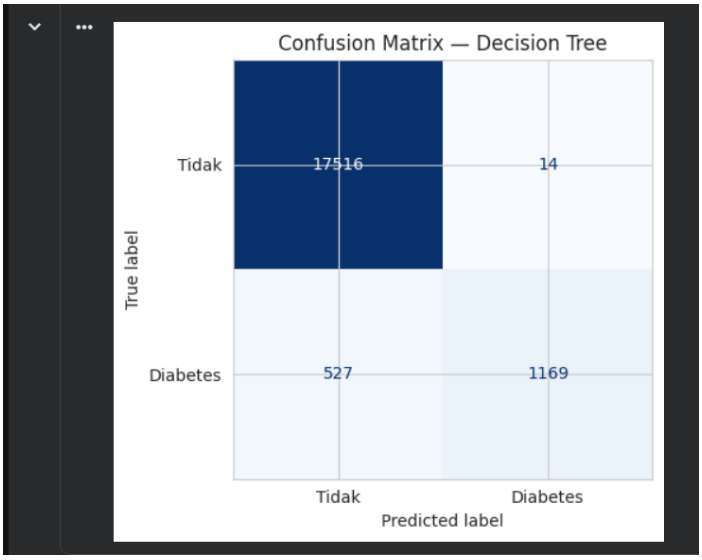
fig, ax = plt.subplots(figsize=(5.5, 4.5))
ConfusionMatrixDisplay(confusion_matrix(y_test, y_pred_dt),
                       display_labels=["Tidak", "Diabetes"]).plot(ax=ax, cmap="Blues", colorbar=False)
ax.set_title("Confusion Matrix — Decision Tree")
plt.tight_layout(); plt.show()
```

```
Akurasi    : 0.9719
Presisi    : 0.9882
Recall     : 0.6893
F1-Score   : 0.8121
ROC-AUC    : 0.9719

=== CLASSIFICATION REPORT ===
                precision    recall  f1-score   support

Tidak Diabetes       0.97      1.00      0.98     17530
      Diabetes       0.99      0.69      0.81      1696

      accuracy                           0.97     19226
     macro avg       0.98      0.84      0.90     19226
  weighted avg       0.97      0.97      0.97     19226
```



Gambar 3.14 Tangkapan layar kode dan keluaran Langkah 14

3.16 Langkah 15: Decision Tree: Visualisasi Pohon dan Feature Importance

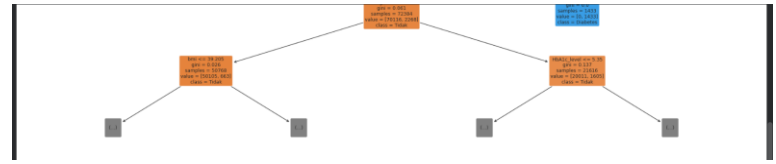
plot_tree() menggambar pohon hingga kedalaman 3 agar terbaca, kemudian feature_importances_ ditampilkan dalam diagram batang horizontal.

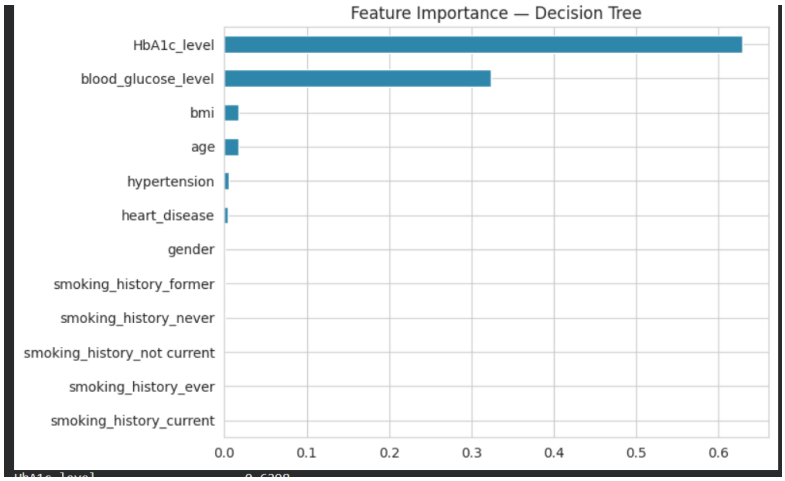
Fitur terpenting adalah HbA1c_level (0,6298) dan blood_glucose_level (0,3242) yang bersama-sama menyumbang sekitar 95% kepentingan. Fitur berikutnya jauh lebih kecil: bmi (0,0175), age (0,0174), hypertension (0,0052), dan heart_disease (0,0044). Hasil ini sejalan dengan korelasi pada Langkah 8 dan dengan pemahaman klinis bahwa HbA1c dan glukosa merupakan indikator utama diabetes.

Langkah 15 — Decision Tree: visualisasi pohon & feature importance

```
[15]
✓ 0 d
#202431100_SaidAqielSyafaraz
fig, ax = plt.subplots(figsize=(20, 8))
plot_tree(dt_best, feature_names=X.columns, class_names=["Tidak", "Diabetes"],
          filled=True, rounded=True, max_depth=3, fontsize=9, ax=ax)
ax.set_title("Visualisasi Decision Tree (ditampilkan sampai kedalaman 3)")
plt.tight_layout(); plt.show()

imp = pd.Series(dt_best.feature_importances_, index=X.columns).sort_values()
fig, ax = plt.subplots(figsize=(8, 5))
imp.plot(kind="barh", color="#2E86AB", ax=ax)
ax.set_title("Feature Importance — Decision Tree")
plt.tight_layout(); plt.show()
print(imp.sort_values(ascending=False).round(4))
```






```
HbA1c_level                0.6298
blood_glucose_level        0.3242
bmi                        0.0175
age                        0.0174
hypertension               0.0052
heart_disease              0.0044
gender                     0.0007
smoking_history_former     0.0005
smoking_history_never      0.0003
smoking_history_not current    0.0000
smoking_history_current    0.0000
smoking_history_ever       0.0000
dtype: float64
```

Gambar 3.15 Tangkapan layar kode dan keluaran Langkah 15

3.17 Langkah 16: Regresi Linear: Pelatihan Model

LinearRegression dilatih pada X_train_sc dan y_train. Intersep dan koefisien setiap fitur ditampilkan dan diurutkan.

Intersep 0,0882 (sama dengan proporsi kelas positif pada data latih). Koefisien terbesar: blood_glucose_level 0,0948, HbA1c_level 0,0890, age 0,0323, bmi 0,0274, hypertension 0,0252, dan

heart_disease 0,0224. Seluruh koefisien positif dan urutannya konsisten dengan feature importance Decision Tree.

Langkah 16 — Regresi Linear: pelatihan model

[16] 0d

```
#202431100_SaidAqielSyafaraz
lin_reg = LinearRegression()
lin_reg.fit(X_train_sc, y_train)

koef = pd.Series(lin_reg.coef_, index=X.columns).sort_values(ascending=False)
print("Intercept :", round(lin_reg.intercept_, 4))
print("\nKoefisien regresi (fitur sudah di-scaling):")
print(koef.round(4))
```

```
Intercept : 0.0882

Koefisien regresi (fitur sudah di-scaling):
blood_glucose_level            0.0948
HbA1c_level                    0.0890
age                            0.0323
bmi                            0.0274
hypertension                   0.0252
heart_disease                  0.0224
gender                         0.0075
smoking_history_former         0.0069
smoking_history_never          0.0034
smoking_history_not current    0.0023
smoking_history_current        0.0013
smoking_history_ever           0.0009
dtype: float64
```

Gambar 3.16 Tangkapan layar kode dan keluaran Langkah 16

3.18 Langkah 17: Regresi Linear: Evaluasi

Model memprediksi nilai kontinu pada data uji. Metrik regresi (MAE, MSE, RMSE, R^2) dihitung dari nilai kontinu tersebut. Selanjutnya prediksi dikonversi menjadi kelas dengan ambang 0,5 (≥ 0,5 menjadi diabetes) untuk menghitung akurasi, presisi, recall, F1-score, ROC-AUC, dan confusion matrix, serta histogram sebaran nilai prediksi.

Metrik regresi: MAE 0,1574, MSE 0,0521, RMSE 0,2283, dan R^2 0,3521, artinya model hanya menjelaskan sekitar 35% variasi target. Metrik klasifikasi: akurasi 0,9396, presisi 0,9908, recall 0,3184, F1-score 0,4819, dan ROC-AUC 0,9516. Confusion matrix: TN = 17.525, FP = 5, FN = 1.156, dan TP = 540. Recall rendah karena ambang 0,5 terlalu tinggi untuk target yang hanya 8,8% positif sehingga mayoritas pasien diabetes tidak melewati ambang.

Langkah 17 — Regresi Linear: evaluasi (metrik regresi + akurasi klasifikasi)

```
#202431100_SaidAqielSyafaraz
y_cont_lr = lin_reg.predict(X_test_sc)
y_pred_lr = (y_cont_lr >= 0.5).astype(int)

print("=== METRIK REGRESI ===")
print(f"MAE  : {mean_absolute_error(y_test, y_cont_lr):.4f}")
print(f"MSE  : {mean_squared_error(y_test, y_cont_lr):.4f}")
print(f"RMSE : {np.sqrt(mean_squared_error(y_test, y_cont_lr)):.4f}")
print(f"R2   : {r2_score(y_test, y_cont_lr):.4f}")

hasil_lr = {
    "Akurasi":   accuracy_score(y_test, y_pred_lr),
    "Presisi":   precision_score(y_test, y_pred_lr, zero_division=0),
    "Recall":    recall_score(y_test, y_pred_lr),
    "F1-Score":  f1_score(y_test, y_pred_lr),
    "ROC-AUC":   roc_auc_score(y_test, y_cont_lr),
}
print("\n=== METRIK KLASIFIKASI (threshold 0.5) ===")
for k, v in hasil_lr.items():
    print(f"{k:10s}: {v:.4f}")
print("\n", classification_report(y_test, y_pred_lr, target_names=["Tidak Diabetes", "Diabetes"], zero_division=0))

fig, axes = plt.subplots(1, 2, figsize=(13, 4.8))
ConfusionMatrixDisplay(confusion_matrix(y_test, y_pred_lr),
                       display_labels=["Tidak", "Diabetes"]).plot(ax=axes[0], cmap="Oranges", colorbar=False)
axes[0].set_title("Confusion Matrix — Regresi Linear")
```

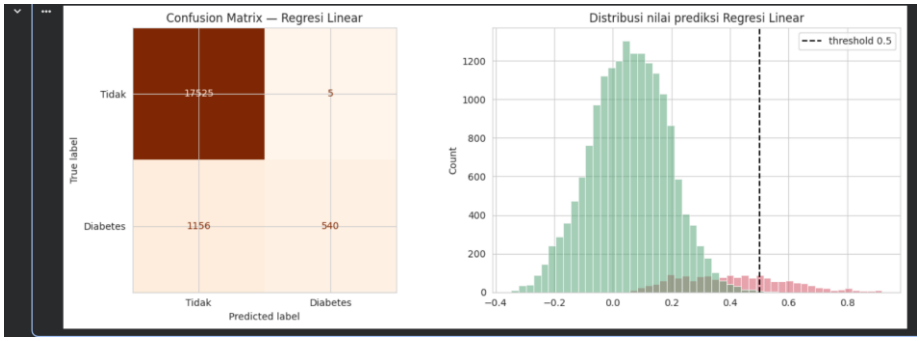
```
=== METRIK REGRESI ===
MAE  : 0.1574
MSE  : 0.0521
RMSE : 0.2283
R2   : 0.3521

=== METRIK KLASIFIKASI (threshold 0.5) ===
Akurasi   : 0.9396
Presisi   : 0.9908
Recall    : 0.3184
F1-Score  : 0.4819
ROC-AUC   : 0.9516

                precision    recall  f1-score   support

Tidak Diabetes       0.94      1.00      0.97     17530
     Diabetes        0.99      0.32      0.48      1696

      accuracy                           0.94     19226
     macro avg        0.96      0.66      0.72     19226
  weighted avg        0.94      0.94      0.93     19226
```



Gambar 3.17 Tangkapan layar kode dan keluaran Langkah 17

3.19 Langkah 18: Perbandingan Decision Tree dan Regresi Linear

Hasil kedua model disusun ke dalam tabel dan diagram batang berkelompok. Kode juga memilih model dengan akurasi tertinggi secara otomatis.

Decision Tree unggul pada akurasi (97,19% vs 93,96%), recall (0,6893 vs 0,3184), F1-score (0,8121 vs 0,4819), dan ROC-AUC (0,9719 vs 0,9516). Regresi Linear sedikit lebih tinggi pada presisi (0,9908 vs 0,9882). Model dengan akurasi tertinggi adalah Decision Tree.

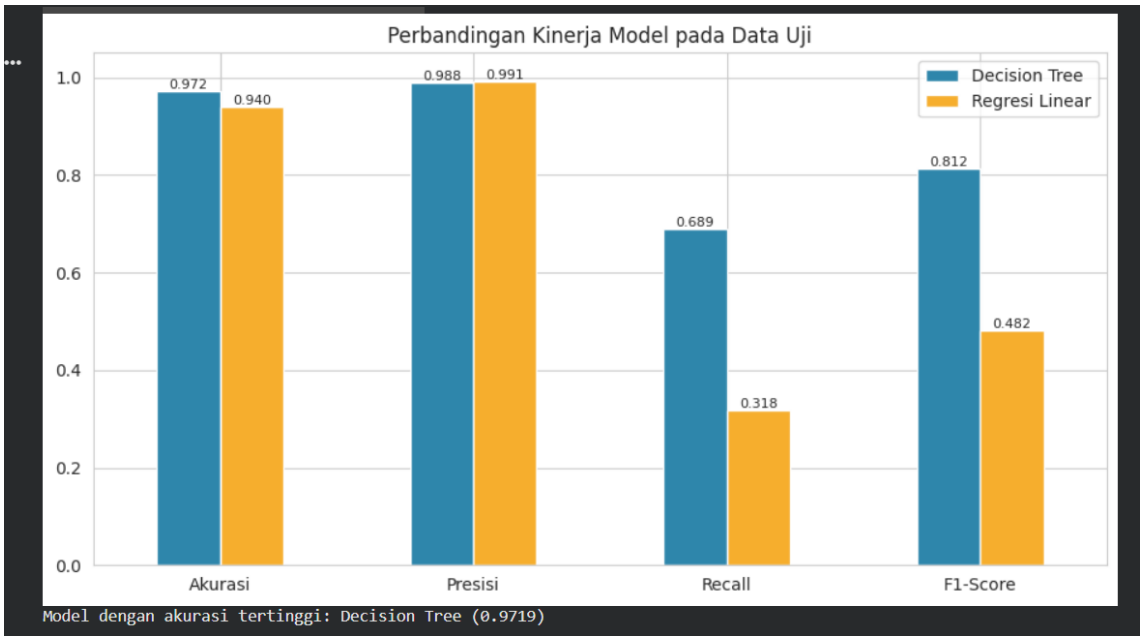
Langkah 18 — Perbandingan Decision Tree vs Regresi Linear

```
[18]
✓ 0 d
#202431100_SaidAqielSyafaraz
tabel = pd.DataFrame({"Decision Tree": hasil_dt, "Regresi Linear": hasil_lr}).round(4)
display(tabel)

ax = tabel.drop(index="ROC-AUC").plot(kind="bar", figsize=(9, 5), color=["#2E86AB", "#F6AE2D"], rot=0)
ax.set_ylim(0, 1.05); ax.set_title("Perbandingan Kinerja Model pada Data Uji")
for c in ax.containers:
    ax.bar_label(c, fmt="%.3f", fontsize=8)
plt.tight_layout(); plt.show()

terbaik = tabel.loc["Akurasi"].idxmax()
print(f"Model dengan akurasi tertinggi: {terbaik} ({tabel.loc['Akurasi'].max():.4f})")
```

	Decision Tree	Regresi Linear
Akurasi	0.9719	0.9396
Presisi	0.9882	0.9908
Recall	0.6893	0.3184
F1-Score	0.8121	0.4819
ROC-AUC	0.9719	0.9516



Gambar 3.18 Tangkapan layar kode dan keluaran Langkah 18

3.20 Langkah 19: Uji Prediksi pada Contoh Pasien Baru

Dibuat satu data pasien fiktif (laki-laki, usia 55, hipertensi, BMI 31,5, HbA1c 7,0, glukosa 200, mantan perokok). Urutan kolom disamakan dengan data latih dan masing-masing model memprediksi. Data untuk Regresi Linear distandardisasi dengan scaler yang sama.

Decision Tree memprediksi DIABETES, sedangkan Regresi Linear menghasilkan nilai 0,497 sehingga diklasifikasikan TIDAK DIABETES karena berada tepat di bawah ambang 0,5. Contoh ini memperlihatkan konsekuensi dari recall Regresi Linear yang rendah.

Langkah 19 — Uji prediksi pada contoh pasien baru

```
[19]
0d
#202431100_SaidAqielSyafaraz
pasien = pd.DataFrame([{
    "gender": 1, "age": 55, "hypertension": 1, "heart_disease": 0, "bmi": 31.5,
    "HbA1c_level": 7.0, "blood_glucose_level": 200,
    "smoking_history_current": 0, "smoking_history_ever": 0, "smoking_history_former": 1,
    "smoking_history_never": 0, "smoking_history_not current": 0,
}])[X.columns]          # urutan kolom disamakan dengan data latih

p_dt = dt_best.predict(pasien)[0]
p_lr = lin_reg.predict(scaler.transform(pasien))[0]
print("Data pasien:"); display(pasien.T.rename(columns={0: "nilai"}))
print(f"Prediksi Decision Tree : {'DIABETES' if p_dt == 1 else 'TIDAK DIABETES'}")
print(f"Prediksi Regresi Linear: nilai {p_lr:.3f} -> {'DIABETES' if p_lr >= 0.5 else 'TIDAK DIABETES'}")
```

```
Data pasien:
```

	nilai
gender	1.0
age	55.0
hypertension	1.0
heart_disease	0.0
bmi	31.5
HbA1c_level	7.0
blood_glucose_level	200.0
smoking_history_current	0.0
smoking_history_ever	0.0
smoking_history_former	1.0
smoking_history_never	0.0
smoking_history_not current	0.0

```
Prediksi Decision Tree : DIABETES
Prediksi Regresi Linear: nilai 0.497 -> TIDAK DIABETES
```

Gambar 3.19 Tangkapan layar kode dan keluaran Langkah 19

3.21 Langkah 20: Ringkasan Hasil Otomatis

Sel terakhir mencetak ringkasan: jumlah data setelah preprocessing, akurasi, recall, dan F1-score kedua model, serta model terbaik.

Data akhir 96.128 baris. Akurasi Decision Tree 97,19% dan Regresi Linear 93,96%. Model terbaik berdasarkan akurasi adalah Decision Tree.

Langkah 20 — Kesimpulan otomatis

```
[20]
✓ 0 d
#202431100_SaidAqielSyafaraz
print("RINGKASAN HASIL UTS")
print("-" * 55)
print(f"Jumlah data setelah preprocessing : {len(df_clean)}")
print(f"Akurasi Decision Tree             : {hasil_dt['Akurasi']*100:.2f}%")
print(f"Akurasi Regresi Linear (thr 0.5)  : {hasil_lr['Akurasi']*100:.2f}%")
print(f"Recall   Decision Tree / Reg.Lin. : {hasil_dt['Recall']:.3f} / {hasil_lr['Recall']:.3f}")
print(f"F1-Score Decision Tree / Reg.Lin. : {hasil_dt['F1-Score']:.3f} / {hasil_lr['F1-Score']:.3f}")
print("-" * 55)
print("Model terbaik berdasarkan akurasi :", terbaik)

RINGKASAN HASIL UTS
-------------------------------------------------------
Jumlah data setelah preprocessing : 96128
Akurasi Decision Tree             : 97.19%
Akurasi Regresi Linear (thr 0.5)  : 93.96%
Recall   Decision Tree / Reg.Lin. : 0.689 / 0.318
F1-Score Decision Tree / Reg.Lin. : 0.812 / 0.482
-------------------------------------------------------
Model terbaik berdasarkan akurasi : Decision Tree
```

Gambar 3.20 Tangkapan layar kode dan keluaran Langkah 20

3.22 Rekapitulasi dan Analisis Hasil

Tabel 3.2 merangkum kinerja kedua model pada data uji sebanyak 19.226 pasien, yang terdiri dari 17.530 pasien non-diabetes dan 1.696 pasien diabetes.

Tabel 3.2 Perbandingan kinerja model pada data uji

Metrik	Decision Tree	Regresi Linear (ambang 0,5)
Akurasi	0,9719	0,9396
Presisi	0,9882	0,9908
Recall	0,6893	0,3184
F1-Score	0,8121	0,4819
ROC-AUC	0,9719	0,9516
True Positive / False Negative	1.169 / 527	540 / 1.156
False Positive / True Negative	14 / 17.516	5 / 17.525

Berdasarkan akurasi, Decision Tree (97,19%) mengungguli Regresi Linear (93,96%) dengan selisih 3,23 poin persentase. Namun akurasi perlu dibaca hati-hati karena model yang selalu menebak "tidak diabetes" akan memperoleh akurasi sekitar 91,18% pada data uji. Dengan pembanding tersebut, Regresi Linear hanya menambah sekitar 2,8 poin di atas tebakan mayoritas, sedangkan Decision Tree menambah sekitar 8 poin. Hal ini sejalan dengan peringatan Owusu-Adjei dkk. (2023) bahwa akurasi pada data kelas tidak seimbang dapat memberi kesan keliru.

Perbedaan terbesar terletak pada recall. Decision Tree menemukan 68,93% pasien diabetes, sedangkan Regresi Linear hanya 31,84%. Pada kedua model presisi sangat tinggi (lebih dari 98%) sehingga hampir tidak ada pasien sehat yang salah diklasifikasikan, tetapi Regresi Linear melewatkan 1.156 pasien diabetes. Dalam konteks penapisan penyakit, kesalahan jenis ini (False Negative) lebih

berbahaya. Selain itu R^2 Regresi Linear hanya 0,3521, yang menandakan hubungan antara fitur dan target tidak sepenuhnya linear. Decision Tree dapat membuat aturan bertingkat dan interaksi, misalnya kombinasi HbA1c tinggi dan glukosa tinggi, yang tidak dapat ditangkap oleh satu persamaan linear.

Hasil ini berbeda dari temuan Cerono dan Chicco (2024), yang pada tugas regresi durasi diabetes menemukan Regresi Linear mengungguli Decision Tree. Perbedaan tersebut dapat dijelaskan oleh perbedaan tugas, ukuran data, dan konfigurasi model: pada praktikum ini target berupa kelas biner, jumlah data sangat besar (96.128 baris), dan kedalaman pohon dikendalikan melalui GridSearchCV sehingga tidak overfitting. Hal ini mendukung kesimpulan bahwa pemilihan algoritma bergantung pada karakteristik data.

Beberapa keterbatasan perlu dicatat. Pertama, Regresi Linear tidak dirancang untuk target biner, sehingga ambang 0,5 bukan ambang optimal; penyetelan ambang yang lebih rendah berpotensi meningkatkan recall. Kedua, ketidakseimbangan kelas tidak ditangani dengan teknik khusus seperti pembobotan kelas atau oversampling; dengan teknik tersebut recall Decision Tree dapat meningkat. Ketiga, outlier BMI tidak dihapus sehingga dapat memengaruhi koefisien Regresi Linear. Keempat, evaluasi menggunakan satu kali pembagian data uji, sehingga validasi silang pada kedua model dapat memberi estimasi yang lebih stabil.

BAB IV
PENUTUP

Berdasarkan landasan teori dan hasil praktikum yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut.

1. Dataset diabetes terdiri dari 100.000 baris dan 9 kolom tanpa nilai hilang, tetapi memiliki 3.854 baris duplikat, 18 data gender Other, dan ketidakseimbangan kelas (8,5% diabetes). Fitur dengan korelasi tertinggi terhadap target adalah blood_glucose_level (0,420) dan HbA1c_level (0,401).
2. Preprocessing berupa penghapusan duplikat, penghapusan gender Other, encoding gender dan smoking_history, pembagian data 80 : 20 berstrata, dan standardisasi untuk Regresi Linear menghasilkan 96.128 data bersih yang terbagi menjadi 76.902 data latih dan 19.226 data uji.
3. Decision Tree dasar mengalami overfitting (akurasi latih 99,92% dan uji 95,04%). Setelah dituning dengan GridSearchCV (criterion gini, max_depth 10, min_samples_leaf 50), akurasi uji meningkat menjadi 97,19% dengan presisi 0,9882, recall 0,6893, F1-score 0,8121, dan ROC-AUC 0,9719. Fitur terpenting adalah HbA1c_level (0,6298) dan blood_glucose_level (0,3242).
4. Regresi Linear dengan ambang 0,5 menghasilkan akurasi 93,96%, presisi 0,9908, recall 0,3184, F1-score 0,4819, dan ROC-AUC 0,9516, dengan R^2 0,3521, MAE 0,1574, dan RMSE 0,2283. Hubungan fitur dan target tidak sepenuhnya linear sehingga banyak pasien diabetes tidak terdeteksi.
5. Decision Tree merupakan model terbaik pada praktikum ini karena unggul pada akurasi, recall, F1-score, dan ROC-AUC. Akurasi perlu ditafsirkan bersama metrik lain karena tebakan kelas mayoritas saja sudah memberi akurasi sekitar 91%.

Saran untuk pengembangan selanjutnya adalah menangani ketidakseimbangan kelas (class_weight atau SMOTE), menyetel ambang klasifikasi pada Regresi Linear, menambahkan validasi silang, serta membandingkan dengan algoritma ensemble seperti Random Forest atau Gradient Boosting yang pada banyak penelitian terbaru memberikan hasil lebih baik.

DAFTAR PUSTAKA

Cai, S.-S., Zheng, T.-Y., Wang, K.-Y., & Zhu, H.-P. (2024). Clinical study of different prediction models in predicting diabetic nephropathy in patients with type 2 diabetes mellitus. World Journal of Diabetes, 15(1), 43–52.

Cerono, G., & Chicco, D. (2024). Ensemble machine learning reveals key features for diabetes duration from electronic health records. PeerJ Computer Science, 10, e1896. https://doi.org/10.7717/peerj-cs.1896

Ghiasi, Y., dkk. (2024). Diabetes detection via machine learning using four implemented spanning tree algorithms. Journal of Optimization in Industrial Engineering, 17(1), 1–16. https://doi.org/10.22094/QJIE.2024.951302

Nguyen, L. P., Tung, D. D., Nguyen, D. T., Le, H. N., Tran, T. Q., Binh, T. V., & Pham, D. T. N. (2023). The utilization of machine learning algorithms for assisting physicians in the diagnosis of diabetes. Diagnostics, 13(12), 2087. https://doi.org/10.3390/diagnostics13122087

Owusu-Adjei, M., dkk. (2023). Imbalanced class distribution and performance evaluation metrics: A systematic review of prediction accuracy for determining model performance in healthcare systems. PLOS Digital Health, 2(11), e0000290. https://doi.org/10.1371/journal.pdig.0000290

Sen Kaya, O., Bozkurt Keser, S., & Keskin, K. (2023). Early stage diabetes prediction using decision tree-based ensemble learning model. International Advanced Researches and Engineering Journal, 7(1), 62–71. https://doi.org/10.35860/iarej.1188039

Shaukat, Z., Zafar, W., Ahmad, W., Haq, I. U., Husnain, G., Al-Adhaileh, M. H., Ghadi, Y. Y., & Algarni, A. (2023). Revolutionizing diabetes diagnosis: Machine learning techniques unleashed. Healthcare, 11(21), 2864. https://doi.org/10.3390/healthcare11212864